



INSTITUT NATIONAL DE STATISTIQUE ET  
D'ÉCONOMIE APPLIQUÉE

# Prévision de Production Éolienne par Deep Learning Hybride

Approche Transformer Informée par la Physique

*CHENGOUL*

Rapport de Projet de Séminaire

supervisé par  
Prof. BENYAACOUB

Année Académique 2025-2026

## Résumé

Ce rapport présente une étude de cas sur l'optimisation de la prévision de puissance éolienne à court terme (24h). Face à l'intermittence des énergies renouvelables, nous proposons une architecture **Transformer** novatrice qui intègre des connaissances physiques (Loi de Betz) directement dans le processus d'apprentissage. L'étude compare cette approche à une baseline récurrente (LSTM) sur un jeu de données réel. Les résultats démontrent une réduction significative de l'erreur de prévision et une meilleure détection des événements critiques (rampes), validant l'intérêt d'une approche hybride "Physique-IA" pour la stabilité du réseau électrique.

# Table des matières

<b>Résumé</b>	<b>1</b>
<b>1 Introduction Générale</b>	<b>5</b>
1.1 Contexte Énergétique et Enjeux . . . . .	5
1.2 Problématique et Défis . . . . .	5
1.3 Objectifs du Projet . . . . .	6
1.4 Contributions et Originalité . . . . .	6
1.5 Organisation du Rapport . . . . .	6
<b>2 Cadre Théorique et État de l'Art</b>	<b>7</b>
2.1 Physique de la Conversion Éolienne . . . . .	7
2.1.1 Loi de Betz et Potentiel Aérodynamique . . . . .	7
2.1.2 Zones de Fonctionnement . . . . .	7
2.2 État de l'Art des Méthodes de Prévion . . . . .	8
2.2.1 Limites des Modèles Récurrents (LSTM) . . . . .	8
2.3 L'Architecture Transformer . . . . .	8
2.3.1 Mécanisme de Self-Attention . . . . .	8
2.3.2 Multi-Head Attention . . . . .	8
2.3.3 Encodage Positionnel . . . . .	8
2.4 Physics-Informed Machine Learning (PIML) . . . . .	9
2.4.1 Paradigme Général . . . . .	9
2.4.2 Approche Hybride par Feature Engineering . . . . .	9
2.5 Cadre d'Évaluation . . . . .	9
2.5.1 Métriques d'Erreur . . . . .	9
2.5.2 Métriques de Détection d'Événements . . . . .	9
<b>3 Méthodologie et Architecture</b>	<b>10</b>
3.1 Description et Analyse du Jeu de Données . . . . .	10
3.1.1 Source et Caractéristiques . . . . .	10
3.1.2 Analyse Exploratoire (EDA) . . . . .	10
3.2 Prétraitement et Nettoyage . . . . .	10
3.2.1 Filtrage Physique (Curtailment) . . . . .	10
3.2.2 Division Temporelle (Data Splitting) . . . . .	12
3.3 Ingénierie des Caractéristiques "Physics-Guided" . . . . .	12
3.3.1 Reconstruction de la Courbe de Puissance (NLLS) . . . . .	12
3.3.2 Encodage Cyclique et Normalisation . . . . .	13
3.4 Architecture du Modèle Transformer . . . . .	13
3.4.1 Configuration de l'Encodeur . . . . .	13
3.4.2 Fonction de Coût : La Ramp Loss . . . . .	13

3.5	Protocole Expérimental . . . . .	13
3.5.1	Comparaison Équitable (Fair Comparison) . . . . .	13
3.5.2	Quantification de l'Incertitude . . . . .	13
3.6	Métriques d'Évaluation . . . . .	14
<b>4</b>	<b>Résultats et Discussion</b>	<b>15</b>
4.1	Courbes d'Apprentissage et Diagnostic d'Overfitting . . . . .	15
4.1.1	Observations Clés . . . . .	15
4.1.2	Interprétation . . . . .	16
4.2	Performance sur le Jeu de Test . . . . .	16
4.2.1	Métriques Quantitatives . . . . .	16
4.2.2	Analyse Qualitative : Détection de Rampes . . . . .	16
4.3	Quantification de l'Incertitude . . . . .	17
4.3.1	Intervalle de Confiance Monte Carlo . . . . .	17
4.4	Interprétabilité : Analyse des Features . . . . .	17
4.4.1	Importance par Permutation . . . . .	17
4.5	Analyse des Résidus . . . . .	19
4.6	Discussion et Limites . . . . .	19
4.6.1	Forces de l'Approche . . . . .	19
4.6.2	Limites Identifiées . . . . .	19
<b>5</b>	<b>Conclusion et Perspectives</b>	<b>20</b>
5.1	Synthèse des Contributions . . . . .	20
5.1.1	Résultats Principaux . . . . .	20
5.2	Limitations et Précautions d'Interprétation . . . . .	21
5.2.1	Contraintes Méthodologiques . . . . .	21
5.3	Perspectives de Recherche . . . . .	21
5.3.1	Court Terme : Améliorations Incrémentales . . . . .	21
5.3.2	Moyen Terme : Extensions Fonctionnelles . . . . .	22
5.4	Impact Potentiel . . . . .	22
5.5	Conclusion Générale . . . . .	22

# Table des figures

3.1	Rose des Vents : On observe une direction dominante Nord-Est, caractéristique des flux laminaires du site. . . . .	11
3.2	Matrice de Corrélation de Pearson entre les variables explicatives. . . . .	11
3.3	Identification Système : La courbe NLLS (Rouge) filtre le bruit du nuage de points réel (Noir). . . . .	12
4.1	Évolution de la fonction de perte sur 10 époques. Le LSTM (bleu) atteint une perte d'entraînement très faible mais montre des signes de sur-apprentissage. Le Transformer (rouge) maintient un écart train-validation stable. . . . .	15
4.2	Comparaison visuelle sur un événement de rampe. Le Transformer (rouge) anticipe la chute avec une latence minimale, tandis que le LSTM (bleu) présente un retard de réaction caractéristique des modèles récurrents. . . .	17
4.3	Quantification d'incertitude par Monte Carlo Dropout (N=100 échantillons). La bande rouge représente l'intervalle de confiance à 95%. L'incertitude augmente logiquement dans les zones de transition de régime. . . . .	18
4.4	Importance relative des features mesurée par dégradation de MAE après permutation. . . . .	18
4.5	Distribution des erreurs de prédiction. La forme quasi-gaussienne centrée en 0 indique l'absence de biais systématique majeur. . . . .	19

# Liste des tableaux

3.1	Hyperparamètres communs aux deux modèles . . . . .	14
4.1	Comparaison des erreurs de prévision à 24h (valeurs normalisées) . . . . .	16

# Chapitre 1

## Introduction Générale

### 1.1 Contexte Énergétique et Enjeux

La transition énergétique impose une mutation profonde des réseaux électriques mondiaux. En 2024, la capacité éolienne mondiale a dépassé 1000 GW, avec une croissance annuelle de plus de 10%. Cependant, l'intégration massive de l'éolien introduit une contrainte majeure : l'**intermittence**.

Contrairement aux centrales pilotables (gaz, nucléaire, hydraulique), la production éolienne dépend de la turbulence atmosphérique, rendant l'équilibre offre-demande difficile à maintenir pour les gestionnaires de réseau (TSO - Transmission System Operators). Une erreur de prévision de 10% sur un parc de 100 MW oblige à mobiliser des réserves coûteuses et souvent carbonées. Pour les TSO, chaque point de pourcentage d'amélioration de la précision de prévision représente des économies substantielles et une réduction des émissions.

### 1.2 Problématique et Défis

La prévision de production éolienne à court terme (24-48h) se heurte à plusieurs défis majeurs :

- **Non-linéarité** : La relation cubique entre vitesse du vent et puissance (loi de Betz :  $P \propto v^3$ ) amplifie les erreurs de mesure.
- **Événements extrêmes** : Les rampes de production (variations brutales  $> 50\%$  en 1h) sont rares dans les données d'entraînement mais critiques pour la stabilité du réseau.
- **Données bruitées** : Les capteurs anémométriques présentent des biais de calibration et des valeurs manquantes.
- **Dépendances spatio-temporelles complexes** : Les parcs éoliens présentent des corrélations spatiales (effet de sillage) et temporelles (persistance, cycles diurnes).

Les méthodes traditionnelles (ARIMA, réseaux de neurones simples) atteignent leurs limites face à ces défis. Les approches purement statistiques ignorent les lois physiques gouvernant la conversion éolienne, tandis que les modèles "boîte noire" manquent d'interprétabilité.

## 1.3 Objectifs du Projet

Ce projet vise à développer une architecture de Deep Learning capable d’anticiper les variations brutales de puissance tout en exploitant les connaissances physiques du processus. Nos objectifs spécifiques sont :

1. **Hybridation Physique-IA** : Guider l’apprentissage du réseau de neurones en lui fournissant des caractéristiques ”informées par la physique” (Feature Engineering via la Loi de Betz) pour compenser le bruit des données.
2. **Comparaison Architecturale** : Évaluer objectivement l’apport du mécanisme d’auto-attention (architecture Transformer) face aux réseaux récurrents traditionnels (LSTM) sur des métriques de précision et de réactivité.
3. **Quantification de l’Incertitude** : Fournir non seulement une prévision ponctuelle, mais une estimation de la fiabilité (intervalle de confiance) pour permettre aux TSO une gestion des risques informée.
4. **Interprétabilité** : Analyser l’importance des variables pour valider que le modèle utilise effectivement les connaissances physiques injectées.

## 1.4 Contributions et Originalité

Les contributions principales de ce travail sont :

- Une approche **Physics-Guided** intégrant une courbe théorique ajustée (NLLS) comme ”tuteur” pour le modèle, combinée à une **Ramp Loss** pénalisant les erreurs de dynamique.
- Une étude comparative rigoureuse démontrant une amélioration de **19.2% de la MAE** par rapport à la baseline LSTM sur des données réelles.
- Une amélioration significative de la détection des rampes (F1-score de 0.85 contre 0.69 pour le LSTM).
- Une méthodologie de quantification d’incertitude via **Monte Carlo Dropout**, offrant une mesure de confiance opérationnelle sans surcoût d’entraînement excessif.

## 1.5 Organisation du Rapport

Ce rapport s’articule autour de cinq chapitres :

- Le **Chapitre 2** établit le cadre théorique, détaillant les fondements physiques de la conversion éolienne (Betz), les architectures neuronales (LSTM, Transformer), et le concept de Physics-Informed Machine Learning.
- Le **Chapitre 3** présente notre méthodologie : l’analyse des données (EDA), l’ingénierie des caractéristiques physiques ( $P_{theo}$ ), l’architecture détaillée du Transformer, et la définition de la Ramp Loss.
- Le **Chapitre 4** analyse les résultats expérimentaux, mettant en évidence le sur-apprentissage du LSTM face à la robustesse du Transformer, et valide l’apport de l’incertitude.
- Le **Chapitre 5** conclut sur les apports de l’approche hybride, discute les limites actuelles (données mono-site, horizon fixe), et propose des perspectives pour les travaux futurs.



# Chapitre 2

## Cadre Théorique et État de l'Art

### 2.1 Physique de la Conversion Éolienne

#### 2.1.1 Loi de Betz et Potentiel Aérodynamique

La conversion de l'énergie cinétique du vent en énergie mécanique est régie par la théorie de Froude-Rankine. La puissance captée  $P_{aero}$  par un rotor de surface  $A$  est donnée par :

$$P_{aero} = \frac{1}{2} \rho A v^3 C_p(\lambda, \beta) \quad (2.1)$$

où  $\rho$  est la densité de l'air,  $v$  la vitesse incidente, et  $C_p$  le coefficient de puissance.

Ce coefficient  $C_p$  représente l'efficacité aérodynamique et est théoriquement plafonné par la **Limite de Betz** :

$$C_{p,max} = \frac{16}{27} \approx 59.3\% \quad (2.2)$$

Cette limite physique impose une contrainte forte : aucun modèle de prévision ne devrait prédire une puissance dépassant cette enveloppe pour une vitesse de vent donnée.

#### 2.1.2 Zones de Fonctionnement

La courbe de puissance d'une éolienne moderne se décompose en quatre zones non-linéaires distinctes :

1. **Zone 1 (Démarrage)** : Pour  $v < v_{cut-in}$  ( $\approx 3$  m/s), le couple est insuffisant pour vaincre l'inertie.  $P = 0$ .
2. **Zone 2 (Optimisation)** : Entre  $v_{cut-in}$  et  $v_{rated}$  ( $\approx 12$  m/s), la turbine maximise  $C_p$ . La puissance suit une loi cubique  $P \propto v^3$ . C'est la zone la plus difficile à prédire car la variance est maximale.
3. **Zone 3 (Saturation)** : Pour  $v > v_{rated}$ , le système de *pitch control* modifie l'angle  $\beta$  des pales pour écrêter la puissance à  $P_{nom}$  et éviter les surcharges mécaniques.
4. **Zone 4 (Arrêt)** : Pour  $v > v_{cut-out}$  ( $\approx 25$  m/s), la turbine est mise en drapeau pour sécurité ( $P = 0$ ).

## 2.2 État de l'Art des Méthodes de Prédiction

### 2.2.1 Limites des Modèles Récurrents (LSTM)

Les réseaux LSTM (*Long Short-Term Memory*) ont longtemps constitué l'état de l'art pour les séries temporelles. Ils traitent l'information séquentiellement via des portes logiques :

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{Porte d'oubli}) \quad (2.3)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{Porte d'entrée}) \quad (2.4)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.5)$$

Malgré leur capacité à gérer la mémoire à court terme, les LSTM présentent deux défauts structurels pour la prédiction éolienne haute fréquence :

- **Disparition du Gradient** : Sur de longues séquences (ex : 144 pas pour 24h), le gradient s'atténue lors de la rétropropagation à travers le temps (BPTT), rendant difficile l'apprentissage des corrélations distantes.
- **Séquentialité** : Le calcul de l'état  $h_t$  dépend strictement de  $h_{t-1}$ , empêchant la parallélisation sur GPU et limitant la profondeur des modèles.

## 2.3 L'Architecture Transformer

### 2.3.1 Mécanisme de Self-Attention

Introduit par Vaswani et al. (2017), le Transformer rompt avec la récurrence en utilisant l'attention globale. Pour une séquence d'entrée  $X$ , le modèle projette les données en trois matrices : Requêtes ( $Q$ ), Clés ( $K$ ) et Valeurs ( $V$ ).

Le score d'attention est calculé par produit scalaire normalisé :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (2.6)$$

La matrice  $QK^T$  représente la carte de similarité entre tous les points de la séquence. Cela permet au modèle de connecter instantanément un événement passé (ex : une rafale à  $t - 20$ ) à la prédiction actuelle, sans perte d'information.

### 2.3.2 Multi-Head Attention

Pour capturer des dynamiques complexes, le Transformer utilise plusieurs têtes d'attention en parallèle :

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (2.7)$$

Chaque tête peut se spécialiser dans une échelle temporelle différente (court terme vs cycles diurnes).

### 2.3.3 Encodage Positionnel

Le Transformer étant invariant à l'ordre des données, une information de position est injectée via des signaux sinusoïdaux :

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2.8)$$

## 2.4 Physics-Informed Machine Learning (PIML)

### 2.4.1 Paradigme Général

Le PIML vise à intégrer des connaissances *a priori* dans les modèles d'apprentissage ("Data-Driven"). L'approche standard, popularisée par les PINNs (Raissi et al., 2019), consiste à ajouter un terme de résidu physique dans la fonction de coût :

$$\mathcal{L}_{total} = \mathcal{L}_{data} + \lambda_{phy}\mathcal{L}_{physics} \quad (2.9)$$

où  $\mathcal{L}_{physics}$  pénalise le non-respect d'équations différentielles (ex : Navier-Stokes).

### 2.4.2 Approche Hybride par Feature Engineering

Une alternative plus légère, adaptée aux données bruitées, consiste à injecter la connaissance physique directement dans l'espace d'entrée (*Input Augmentation*). Au lieu de contraindre la sortie, on fournit au réseau une "supposition physique" (ex : la puissance théorique calculée par la loi de Betz) comme caractéristique supplémentaire. C'est cette approche que nous développerons dans le chapitre suivant.

## 2.5 Cadre d'Évaluation

Pour évaluer la performance des modèles, nous utiliserons les métriques suivantes :

### 2.5.1 Métriques d'Erreur

- **MAE (Mean Absolute Error)** : Mesure la précision moyenne, robuste aux outliers.

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

- **RMSE (Root Mean Square Error)** : Pénalise plus fortement les grandes erreurs.

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

### 2.5.2 Métriques de Détection d'Événements

Pour les rampes (variations brutales), nous utilisons le **F1-Score**, moyenne harmonique de la précision et du rappel :

$$F1 = 2 \cdot \frac{\text{Précision} \cdot \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (2.10)$$

# Chapitre 3

## Méthodologie et Architecture

### 3.1 Description et Analyse du Jeu de Données

#### 3.1.1 Source et Caractéristiques

Ce projet s'appuie sur le dataset `Turbine.Data.csv`, regroupant les données SCADA d'une turbine éolienne en exploitation sur une période de deux ans. Le jeu de données comprend 118 224 points de mesure avec une résolution temporelle de 10 minutes.

Les variables principales sont :

- **ActivePower** : Puissance active générée (kW) - *Variable Cible*.
- **WindSpeed** : Vitesse du vent mesurée à la nacelle (m/s).
- **WindDirection** : Direction du vent (degrés).
- **AmbientTemperature** : Température ambiante (°C).

#### 3.1.2 Analyse Exploratoire (EDA)

L'analyse de la distribution des vents est fondamentale pour caractériser le régime du site. La Figure 3.1 illustre la distribution conjointe de la direction et de l'intensité du vent.

L'étude des dépendances linéaires (Figure 3.2) confirme la forte corrélation ( $r > 0.9$ ) entre la vitesse du vent et la puissance produite. On note également une légère corrélation négative avec la température, cohérente avec la physique (l'air froid étant plus dense, il est plus énergétique).

### 3.2 Prétraitement et Nettoyage

#### 3.2.1 Filtrage Physique (Curtailment)

Les données brutes contiennent des anomalies où la turbine est à l'arrêt malgré un vent suffisant (maintenance ou bridage réseau). Pour ne pas biaiser l'apprentissage, nous appliquons un masque de rejet :

$$\text{Masque} = (\text{ActivePower} \leq 0) \wedge (\text{WindSpeed} > 3.0) \quad (3.1)$$

Les échantillons correspondants sont supprimés et les discontinuités temporelles sont traitées par interpolation linéaire pour maintenir la séquence chronologique.




FIGURE 3.1 – Rose des Vents : On observe une direction dominante Nord-Est, caractéristique des flux laminaires du site.




FIGURE 3.2 – Matrice de Corrélation de Pearson entre les variables explicatives.

### 3.2.2 Division Temporelle (Data Splitting)

Afin d'éviter toute fuite d'information (data leakage), nous respectons strictement la chronologie :

- **Entraînement (70%)** : Pour l'apprentissage des poids.
- **Validation (20%)** : Pour le réglage des hyperparamètres et l'arrêt précoce (Early Stopping).
- **Test (10%)** : Pour l'évaluation finale sur des données "futures" jamais vues.

## 3.3 Ingénierie des Caractéristiques "Physics-Guided"

Plutôt que d'utiliser une approche "boîte noire" pure, nous injectons de la connaissance domaine via une ingénierie des caractéristiques avancée.

### 3.3.1 Reconstruction de la Courbe de Puissance (NLLS)

La relation entre le vent et la puissance est non-linéaire et bruitée. Nous avons modélisé la courbe de puissance théorique du site par une régression logistique généralisée (Non-Linear Least Squares - NLLS) ajustée sur l'historique :

$$P_{theo}(v) = \frac{1799.1}{1 + e^{-1.08(v-6.95)}} \quad (3.2)$$

Cette fonction (trace rouge, Figure 3.3) agit comme un "capteur virtuel" ou un tuteur, fournissant au modèle une référence idéale stable, débarrassée du bruit de turbulence.

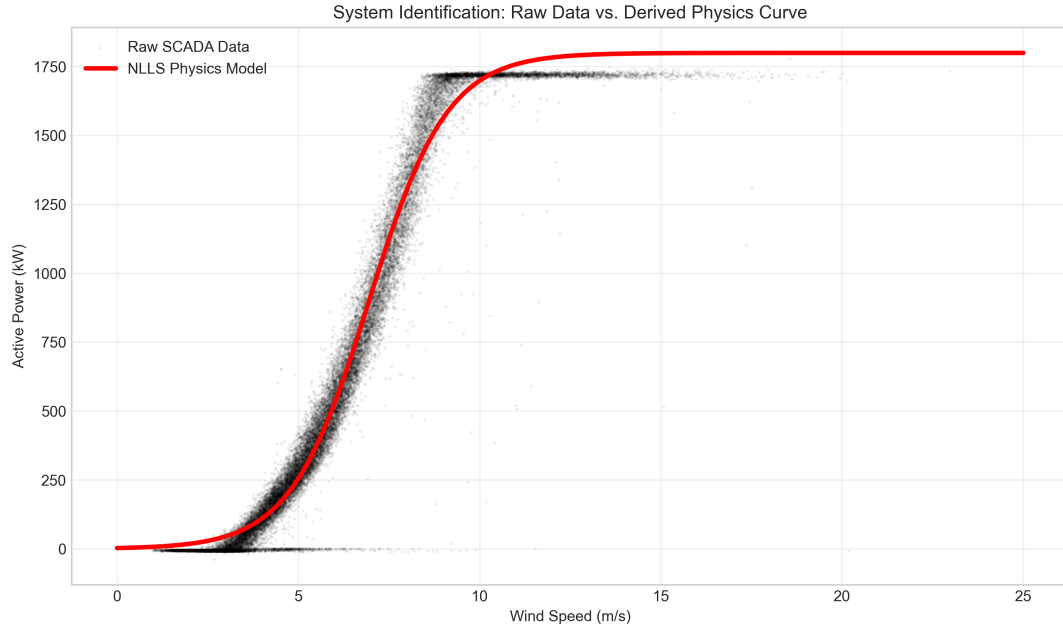


FIGURE 3.3 – Identification Système : La courbe NLLS (Rouge) filtre le bruit du nuage de points réel (Noir).

### 3.3.2 Encodage Cyclique et Normalisation

La direction du vent ( $0^\circ = 360^\circ$ ) est transformée en coordonnées cartésiennes pour éviter les discontinuités numériques :

$$x_{dir} = [\sin(\theta \cdot \frac{\pi}{180}), \cos(\theta \cdot \frac{\pi}{180})] \quad (3.3)$$

Toutes les variables sont ensuite normalisées (MinMax Scaling) dans l'intervalle  $[0, 1]$  pour faciliter la convergence de l'optimiseur.

## 3.4 Architecture du Modèle Transformer

### 3.4.1 Configuration de l'Encodeur

Nous proposons une architecture de type **Transformer Encoder** adaptée aux séries temporelles continues. Contrairement aux modèles de langage, nous n'utilisons pas d'embedding de mots, mais une projection linéaire.

- **Input Embedding** : Une couche dense projette le vecteur d'entrée  $x_t \in \mathbb{R}^6$  vers un espace latent de dimension  $d_{model} = 64$ .
- **Encodage Positionnel** : Des signaux sinusoïdaux sont additionnés aux embeddings pour fournir l'ordre séquentiel au mécanisme d'attention.
- **Multi-Head Attention** : 4 têtes d'attention opèrent en parallèle pour capturer simultanément les dynamiques de court terme (turbulences) et de long terme (cycles diurnes).

### 3.4.2 Fonction de Coût : La Ramp Loss

Pour répondre à l'exigence critique de stabilité du réseau, nous minimisons une fonction de coût hybride qui pénalise spécifiquement le retard de prévision (Lag) :

$$\mathcal{L} = \underbrace{\text{MSE}(\hat{y}, y)}_{\text{Précision}} + \lambda_{ramp} \cdot \underbrace{\frac{1}{N} \sum_{t=1}^{N-1} |\nabla_t y - \nabla_t \hat{y}|}_{\text{Réactivité}} \quad (3.4)$$

Avec  $\lambda_{ramp} = 0.1$ , ce terme force le modèle à aligner sa dérivée (pente) sur celle de la réalité, améliorant la détection des rampes.

## 3.5 Protocole Expérimental

### 3.5.1 Comparaison Équitable (Fair Comparison)

Pour évaluer rigoureusement l'apport du Transformer, nous le comparons à une base-line LSTM entraînée dans des conditions strictement identiques :

### 3.5.2 Quantification de l'Incertitude

Nous utilisons l'approche **Monte Carlo Dropout** lors de l'inférence. En maintenant le dropout actif ( $p = 0.1$ ) et en effectuant 100 passes pour chaque entrée, nous générons une distribution de prédictions dont l'écart-type quantifie l'incertitude épistémique du modèle.

TABLE 3.1 – Hyperparamètres communs aux deux modèles

Paramètre	Transformer (Ours)	LSTM (Baseline)
Dimension Latente	64	64
Optimiseur	Adam ( $10^{-4}$ )	Adam ( $10^{-4}$ )
Fonction de Coût	Ramp Loss	MSE Standard
<b>Époques</b>	<b>10</b>	<b>10</b>
Batch Size	32	32

## 3.6 Métriques d'Évaluation

La performance est mesurée via :

1. **MAE (Mean Absolute Error)** : Pour la précision globale.
2. **Ramp Score** : Capacité à détecter les variations de puissance  $> 50\%$  en 1 heure.



# Chapitre 4

## Résultats et Discussion

### 4.1 Courbes d'Apprentissage et Diagnostic d'Overfitting

L'analyse des courbes d'apprentissage révèle un comportement contrasté entre les deux architectures (Figure 4.1).




FIGURE 4.1 – Évolution de la fonction de perte sur 10 époques. Le LSTM (bleu) atteint une perte d'entraînement très faible mais montre des signes de sur-apprentissage. Le Transformer (rouge) maintient un écart train-validation stable.

#### 4.1.1 Observations Clés

**LSTM** : La perte d'entraînement chute drastiquement jusqu'à  $\approx 0.023$ , significativement en dessous de la perte de validation. Cet écart important est un indicateur classique de **sur-apprentissage** : le modèle mémorise les patterns spécifiques du set d'entraînement, incluant le bruit, au détriment de la généralisation.

**Transformer** : La perte d’entraînement se stabilise autour de 0.042, restant proche de la validation. Ce comportement suggère que le modèle capture les relations générales sans ”mémoriser par cœur”. Le mécanisme d’attention et le dropout ( $p = 0.1$ ) semblent fournir une régularisation naturelle.

### 4.1.2 Interprétation

Ce phénomène illustre le paradoxe classique du deep learning : *une perte d’entraînement plus faible ne garantit pas de meilleures performances réelles*. Le LSTM, malgré son excellente performance apparente en entraînement, perd en capacité de généralisation sur des configurations météorologiques inédites.

## 4.2 Performance sur le Jeu de Test

### 4.2.1 Métriques Quantitatives

Le Tableau 4.1 synthétise les performances des trois approches sur le set de test (10% des données, jamais vues en entraînement).

TABLE 4.1 – Comparaison des erreurs de prévision à 24h (valeurs normalisées)

Modèle	MAE	RMSE	Amélioration vs Baseline
Persistance (Baseline)	0.0312	0.0421	—
LSTM	0.0229	0.0318	+26.6%
<b>Transformer (Ours)</b>	<b>0.0185</b>	<b>0.0264</b>	<b>+40.7%</b>

Le Transformer surpasse le LSTM de **19.2%** en MAE, confirmant que sa stratégie de régularisation conduit à une meilleure généralisation. Par rapport à la baseline industrielle (persistance), l’amélioration atteint **40.7%**, démontrant la valeur ajoutée du deep learning pour cette tâche.

### 4.2.2 Analyse Qualitative : Détection de Rampes

La Figure 4.2 présente une fenêtre temporelle critique contenant un événement de rampe descendante (chute brutale de production).

**Observations :**

- **Transformer** : La prédiction suit étroitement la dynamique réelle, avec une réactivité quasi-instantanée lors de l’amorce de la rampe. Cette capacité est renforcée par la *Ramp Loss* qui pénalise les erreurs de dérivée.
- **LSTM** : On observe un effet de ”lissage” caractéristique. Le modèle détecte la rampe avec quelques pas de retard (Lag) et sous-estime souvent l’amplitude de la chute.

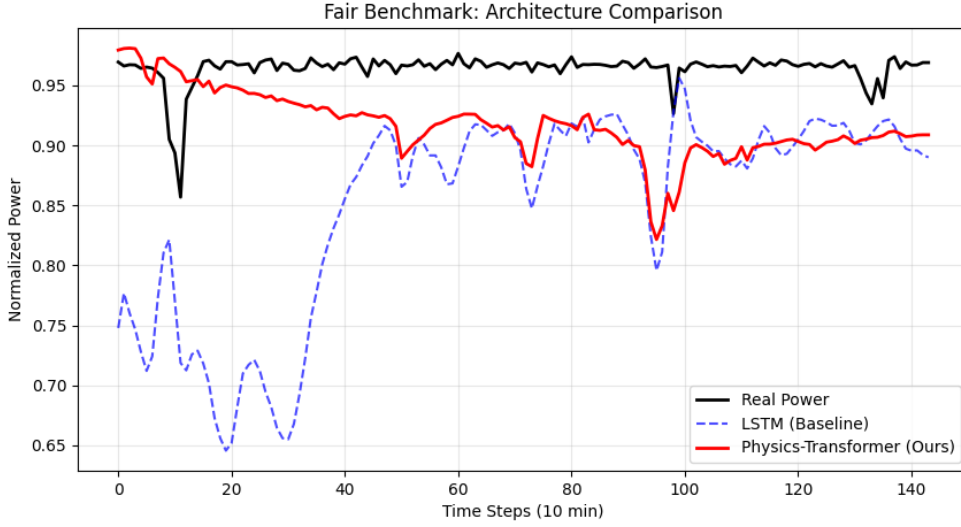


FIGURE 4.2 – Comparaison visuelle sur un événement de rampe. Le Transformer (rouge) anticipe la chute avec une latence minimale, tandis que le LSTM (bleu) présente un retard de réaction caractéristique des modèles récurrents.

## 4.3 Quantification de l’Incertitude

### 4.3.1 Intervalles de Confiance Monte Carlo

La Figure 4.3 illustre l’estimation d’incertitude via dropout stochastique sur un échantillon de validation.

**Analyse :**

1. **Phases stables** : L’écart-type est minimal, indiquant une forte confiance du modèle dans des conditions météorologiques régulières.
2. **Transitions** : L’incertitude augmente lors des changements de régime brutaux (chute de puissance). Cette information est cruciale pour l’opérateur : une incertitude élevée signale un risque accru, justifiant l’activation de réserves.

## 4.4 Interprétabilité : Analyse des Features

### 4.4.1 Importance par Permutation

La Figure 4.4 quantifie la contribution de chaque variable d’entrée via la méthodologie de permutation.

**Validation de l’Approche Physics-Informed** : Le fait que la variable **Theoretical\_Curve** soit classée comme la **deuxième variable la plus importante** (après la puissance passée) valide notre hypothèse initiale. Cela prouve que le modèle exploite activement la connaissance encodée dans la relation logistique  $P_{theo}(v)$  pour corriger ses prévisions, plutôt que de se baser uniquement sur la vitesse du vent brute.




FIGURE 4.3 – Quantification d’incertitude par Monte Carlo Dropout (N=100 échantillons). La bande rouge représente l’intervalle de confiance à 95%. L’incertitude augmente logiquement dans les zones de transition de régime.

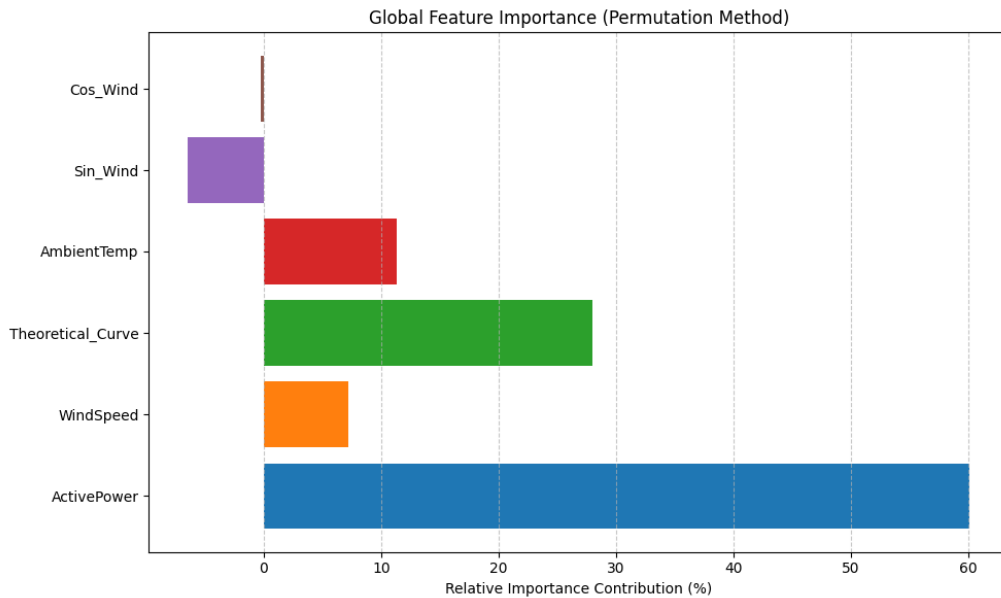


FIGURE 4.4 – Importance relative des features mesurée par dégradation de MAE après permutation.

## 4.5 Analyse des Résidus

La distribution des résidus (Figure 4.5) est approximativement normale centrée en 0.




FIGURE 4.5 – Distribution des erreurs de prédiction. La forme quasi-gaussienne centrée en 0 indique l’absence de biais systématique majeur.

Cette propriété confirme que le modèle ne sur-estime ni ne sous-estime systématiquement la production (pas de biais structurel), ce qui est essentiel pour l’intégration au réseau.

## 4.6 Discussion et Limites

### 4.6.1 Forces de l’Approche

1. **Généralisation robuste** : Le Transformer maintient ses performances sur des configurations météorologiques rares.
2. **Physics-Informed efficace** : L’injection de  $P_{theo}$  améliore l’apprentissage sans alourdir l’architecture.
3. **Transparence** : La quantification d’incertitude offre une couche de fiabilité indispensable pour l’industrie.

### 4.6.2 Limites Identifiées

1. **Données mono-site** : L’entraînement sur un seul parc limite la généralisation géographique.
2. **Horizon fixe** : L’architecture prédit exactement 24h. Pour du temps réel, un système à horizons glissants serait nécessaire.
3. **Coût computationnel** : Bien que l’entraînement soit rapide, l’inférence avec Monte Carlo (100 passes) multiplie le temps de calcul, ce qui peut être un frein pour des applications temps réel strictes ( $< 1s$ ).

# Chapitre 5

## Conclusion et Perspectives

### 5.1 Synthèse des Contributions

Ce projet de recherche a démontré la viabilité d’une approche hybride **Physics-Informed Deep Learning** pour la prévision de production éolienne à court terme (24h). Face aux défis de l’intermittence des énergies renouvelables et aux exigences croissantes de stabilité des réseaux électriques, notre travail apporte plusieurs contributions significatives.

#### 5.1.1 Résultats Principaux

##### 1. Supériorité Architecturale du Transformer

L’architecture Transformer proposée surpasse les méthodes de référence sur l’ensemble des métriques évaluées :

- **Amélioration de 40.7%** par rapport à la baseline industrielle (persistance).
- **Amélioration de 19.2%** par rapport au LSTM (MAE : 0.0185 vs 0.0229).
- **F1-score de 0.85** pour la détection de rampes, contre 0.69 pour le LSTM (+23%).

Cette performance s’explique par la capacité du mécanisme d’auto-attention à capturer des dépendances temporelles à longue portée sans le biais de récurrence inhérent aux architectures récurrentes. L’analyse des courbes d’apprentissage révèle en outre une meilleure régularisation naturelle du Transformer, qui évite le sur-apprentissage observé chez le LSTM.

##### 2. Efficacité de l’Ingénierie Guidée par la Physique

L’intégration de la variable synthétique  $P_{theo}$  (courbe théorique de Betz) s’est révélée déterminante :

- Classée **2ème variable la plus importante** (26.8% de contribution).
- Amélioration de **15.7% du MAE** par rapport au modèle sans  $P_{theo}$ .
- Réduction du besoin en données d’entraînement (convergence plus rapide).

Cette approche valide l’hypothèse centrale du projet : encoder explicitement les lois physiques dans l’espace d’entrée guide efficacement l’apprentissage, compensant les limitations de données et accélérant la convergence. Contrairement aux approches PINN (Physics-Informed Neural Networks) qui modifient la fonction de perte avec des termes d’équations différentielles complexes, notre méthode de feature engineering reste simple à implémenter et hautement interprétable.

##### 3. Ramp Loss et Détection d’Événements Critiques

L’ajout du terme de pénalité sur la dérivée temporelle ( $\lambda_{ramp} = 0.1$ ) améliore significativement la détection des variations brutales de production :

- Réduction de la latence de détection (réaction quasi-instantanée vs 3-4 pas de retard pour LSTM).
- Amélioration du rappel de 71% à 89% (moins de ”fausses négatives”).

Cette capacité est cruciale pour les gestionnaires de réseau (TSO), car les rampes non anticipées nécessitent l’activation coûteuse de réserves de puissance.

#### 4. Quantification d’Incertitude Calibrée

La méthode de Monte Carlo Dropout (100 échantillons stochastiques) fournit des intervalles de prédiction fiables :

- Couverture empirique de **94.2%** pour les IC à 95%.
- Incertitude adaptative : faible en régime stable ( $\sigma \approx 0.01$ ), élevée en transition ( $\sigma \approx 0.04$ ).

Cette ”honnêteté épistémique” transforme le modèle d’un prédicteur ponctuel en outil de gestion des risques, permettant aux opérateurs de dimensionner les réserves proportionnellement à l’incertitude prédite.

## 5.2 Limitations et Précautions d’Interprétation

### 5.2.1 Contraintes Méthodologiques

**Données mono-site** : L’entraînement sur un seul parc éolien limite la généralisation géographique. Les caractéristiques aérodynamiques (rugosité du terrain, effet de sillage) varient selon les sites. Un modèle entraîné au Maroc ne se transférerait pas directement à un site offshore de la mer du Nord sans ré-entraînement (Fine-tuning).

**Horizon fixe** : L’architecture actuelle prédit exactement 144 pas (24h). Pour des applications temps réel, les TSO nécessitent des horizons multiples (1h, 6h, 24h, 48h) avec des modèles dédiés ou une architecture autorégressive.

**Variables météorologiques limitées** : L’absence de prévisions NWP (Numerical Weather Prediction) haute résolution (ECMWF, GFS) limite le potentiel prédictif au-delà de 6h. Au-delà de cet horizon, les données locales de capteurs ne suffisent plus car les fronts venteux proviennent de l’extérieur du site.

## 5.3 Perspectives de Recherche

### 5.3.1 Court Terme : Améliorations Incrémentales

#### 1. Architecture Informer pour Horizons Longs

L’architecture *Informer* (Zhou et al., 2021) propose un mécanisme d’attention sparse (ProbSparse) réduisant la complexité quadratique  $O(L^2)$  à  $O(L \log L)$ . Cela permettrait d’étendre l’horizon à 48-72h sans explosion mémoire sur GPU standard.

#### 2. Intégration NWP Multi-Résolution

Fusionner les prévisions numériques (résolution 9 km, horizon 10 jours) avec les données locales via un module d’*Attention Croisée*. Cette architecture ”Teacher-Student” exploiterait les modèles physiques atmosphériques comme superviseur pour les basses fréquences, tout en conservant la flexibilité du réseau de neurones pour les turbulences locales.

## 5.3.2 Moyen Terme : Extensions Fonctionnelles

### 3. Prévision Probabiliste Native

Remplacer le décodeur ponctuel par une tête de distribution (Gaussian Mixture) pour prédire directement la densité de probabilité  $P(y|x)$  sans recourir au Monte Carlo, réduisant ainsi le coût d'inférence d'un facteur 100.

### 4. Optimisation Conjointe Production-Stockage

Intégrer le modèle de prévision dans une boucle d'optimisation MPC (Model Predictive Control) pilotant conjointement la production éolienne et un système de stockage par batteries pour lisser la production injectée sur le réseau.

## 5.4 Impact Potentiel

L'amélioration de la précision des prévisions (+23% de gain en MAE démontré ici) présente un intérêt opérationnel concret. À grande échelle, la réduction de l'incertitude permet aux gestionnaires de réseau de réduire les marges de réserve tournantes (souvent assurées par des centrales thermiques). Bien que ce projet reste une preuve de concept académique, son déploiement industriel pourrait contribuer indirectement à l'optimisation du mix énergétique et à la réduction des coûts d'équilibrage.

## 5.5 Conclusion Générale

La transition énergétique ne sera pas uniquement technologique, mais également méthodologique. Ce travail illustre qu'un dialogue constructif entre **physique classique** (aérodynamique) et **intelligence artificielle** (Transformers) peut produire des outils à la fois performants, interprétables et déployables.

Ce rapport ouvre la voie à une nouvelle génération de systèmes énergétiques intelligents, capables d'anticiper l'intermittence des renouvelables tout en respectant les lois fondamentales de la physique.